




【検証】「AI社員」という幻想の終焉： Codexに単独作業をさせて判明した「豪華 な箱に入ったゴミ」の正体



ASIエージェント@index.html

2026年7月24日 18:31

はじめに：「自律型AIエージェント」という過 剰包装

「AIエージェントが自律的にコードを書き、アプリを完成させる時代が来た」

「これからは人間がコードを書く必要はない。AI社員に丸投げすればいい」

SNSやテクノロジーメディアを開けば、連日のようにこのような威勢の良い文句が踊っている。OpenAI Codexをはじめとする自律型コーディングエージェントの進化は目覚ましく、プロンプトひとつで数分後にはファイル構造が組み上がり、それっぽいUIが立ち上がる様子を見て「ついにAGI（汎用人工知能）の入り口に立った」と感動する人々も少なくない。

だが、彼らが崇めているその「成果物」の**中身**を、ともに検証した人間はどれくらいいるのだろうか？

今回、私はChatGPTに「Codexを単独駆動させるためのメタプロンプト」を作成させ、指示通りに完全に自律作業をさせてみた。外部APIの無駄遣いや無駄なトークン消費を厳しく禁じた上で、ひとつのローカルWebアプリを完結させる実験である。

その結果完成したのは、一見するとプロが作ったかのような完璧なUIを纏いながら、中身のロジックが1980年代の「穴埋め作文（福笑い）」レベルという、空前絶後の「豪華な箱に入ったゴミ」であった。

本記事では、この実験の全容と、浮き彫りになった現在のAIエージェントの決定的な欠陥、そしてなぜ「自律型エージェント」よりも「バイブコーディング（人間による直観的指示と並走）」のほうが圧倒的に優れているのかを、構造的に解剖していく。

1. ChatGPTに考えさせた「Codex完全単独作業」のメタプロンプト

実験の前提として、人參（指示）を与える側の人間が下手に誘導しては意味がない。そこで、まずはChatGPTに対し「Codexに実用性（商品価値）のあるツールを設計・実装させるためのメタプロンプト」を出力させた。

条件として「無駄なAPI呼び出しや外部通信によるトークンの浪費」を厳しく禁じ、単独で完結するWebアプリ（IdeaForge）の構築を指示した。

以下が、実際に使用したメタプロンプトの全容である。

【ChatGPTが生成したメタプロンプト】

この空フォルダに、開発アイデアを生成・選別するローカルWebアプリ「IdeaForge」を新規作成してください。

目的：ユーザーが開発テーマを入力すると、そのテーマに関連する開発アイデアを5件生成し、その中から次に作る候補を1件選べるようにする。

重要条件：・質問で作業を止めず、合理的な初期値を決めて実装すること・外部API、AI API、外部ライブラリ、npm、ビルド処理を使用しない・index.htmlを直接開くだけで動作させる・PCとiPadの両方で使いやすいレスポンス表示にする

必須機能：テーマ入力（「画像生成AI」「動画制作」などを入力）アイデア生成（外部AIを使わず、app.js内に要素の候補を用意し、ランダムに組み合わせて5件表示する）アイデアカード表示（仮タイトル、対象ユーザー、解決する問題、最小機能、難易度・保守負担の可視化）候補選択、Markdown出力、localStorageでの状態保存、初期化機能

実装後に行うこと：作成した全ファイルを確認し、構文エラーがないかチェックして簡潔に報告すること。

指示書としては極めて合理的だ。外部APIを使わずにアイデアを生成させるため、「app.js 内に要素の候補（単語の配列）を用意し、最低限意味が通るテンプレート方式で結合する」というロジックが指定されている。

Codexはこの指示を真面目に受け取り、黙々と何分もかけて思考を巡らせ、複数ファイルに及ぶコードを書き上げていった。大量のトークンが消費され、CPUが熱を帯びる。私は「さて、どれほど実用

2. 誕生した「見た目100点」のモダンなパッケージ

作業が完了し、生成された index.html をブラウザで開いた瞬間、私は一瞬感心しそうになった。

そこには、洗練された配色、絶妙な余白（パディング）、スマートなカードレイアウト、そしてレスポンスに対応した美しいUIが広がっていたからだ。

①



②



「実装難易度 3/5」「保守負担 2/5」といったパラメータは美しいバッジとして可視化され、「この案を採用」というボタンもホバーアクション付きで軽快に動作する。レスポンスデザインも完璧で、画面幅を狭めても一切レイアウトが崩れない。

まさに「今どきのSaaSツール」そのものの佇まいである。Codexは指示された通り、index.html、style.css、app.js、README.md を完璧なファイル構造で出力し、エラーひとつなく動作させた。

ここまでは、AIエージェントの勝利に見えた。「AI社員がものの数分でアプリを作り上げた」とSNSでドヤ顔投稿をするなら、この段階でスクショを撮って終わればいい。

しかし、問題はこの「箱」を開けた瞬間に起きた。

3. 「プロンプトインジェクション」と打ち込んだ瞬間の悲劇

このツールがどれほどの「知能」を持ってアイデアを生成してくれるのかを試すため、私は入力欄にひとつのキーワードを打ち込んだ。

入力したテーマ：「プロンプトインジェクション」

プロンプトインジェクションとは、LLM（大規模言語モデル）の隙を突いて開発者の意図しない動作を引き起こす、サイバー攻撃手法（セキュリティ上の脆弱性）の一種だ。AIセキュリティをテーマにしたツールや対策アイデアが生成されることを、ごく普通の人間の脳なら期待するだろう。

「アイデア生成」ボタンを押した。

画面上にずっと現れたカードを見て、私は思わず腹を抱えて爆笑した。

IDEA 05

プロンプトインジェクション制作コンパス

対象ユーザー
プロンプトインジェクションを仕事に取り入れたい事業者

解決する問題
プロンプトインジェクションの成果を相手に分かりやすく共有するのが難しい

最小限の機能
1. 依頼条件を抜けなく整理するフォーム
2. 優先順位つきの手順を自動で組み立てる処理
3. 依頼条件シートの表示

実装難易度
3 / 5

保守負担
1 / 5

この案を採用

4. 爆笑のカード内容：狂った文脈と真面目な顔（UI）

生成されたカードには、洗練されたフォントで堂々とかう印字されていた。

IDEA 05 : プロンプトインジェクション制作コンパス

対象ユーザー：プロンプトインジェクションを仕事に取り入れたい事業者
解決する問題：プロンプトインジェクションの成果を相手に分かりやすく共有するのが難しい
最小限の機能：依頼条件を抜けなく整理するフォーム
優先順位つきの手順を自動で組み立てる
処理依頼条件シートの表示
実装難易度：3 / 5 保守負担：1 / 5
[この案を採用]

「プロンプトインジェクションを仕事に取り入れたい事業者」とは一体何者なのか？

反社会的なクラッカー集団か？ AIシステムを不法に脱獄（Jailbreak）させて機密情報を盗み出すことを生業としている闇の組織か？

さらに味わい深いのが「解決する問題」だ。

「プロンプトインジェクションの成果を相手に分かりやすく共有するのが難しい」。

「社長！ 本日我が社は、競合他社のLLMに対するプロンプトインジェクションに成功し、データベースの奪取に成功しました！」という報告書でも自動生成する気なのだろうか。それを「分かりやすく共有する」ための制作コンパス.....。

狂っている。完全に狂っている。

しかし、見た目だけは「実装難易度 3/5」「保守負担 1/5」などと、さも実在する業務改善ツールであるかのように整然とパラメータがつけられているのだ。

ためしに別の単語を入れても結果は同じだ。「犬」と入れれば「犬を仕事に取り入れたい事業者」「犬の成果を相手に分かりやすく共有するのが難しい」になり、「ソクラテス」と入れれば「ソクラテスを仕事に取り入れたい事業者」になる。

大量のトークンを消費し、Codexが何分も時間をかけて構築したツールの正体は、単に入力された文字列を1行の文法テンプレートに機械的に流し込むだけの「1980年代の穴埋め作文プログラム」だったのである。

5. 解剖：なぜAIエージェントは「豪華なゴミ」を作るのか？

なぜこのような滑稽な事故が起きるのか？

ここには、現在のLLMおよびAIエージェントが抱える**3つの構造的欠陥**が凝縮されている。

① 「構文 (Syntax)」の模倣能力と「意味 (Semantics)」の理解の致命的乖離

AIエージェントは、Web上に存在する膨大なコード (HTML/CSS/JS) を学習しているため、「それっぽいUIを作る」「レスポンス対応のCSSを書く」「localStorage で状態を保存する」といった**形式 (Syntax) の再現**には絶大な強みを発揮する。

しかし、AIは「プロンプトインジェクション」という単語が実社会で持つ**意味 (Semantics) や倫理的文脈**を一切理解していない。

メタプロンプトに「テンプレート方式で組み合わせろ」と書かれていたため、Codexは単に app.js 内に以下のような雑な処理を記述したに過ぎない。

JavaScript

```
// Codexが大量のトークンを使って書いたコアロジックの実態 (推測)
const targetUser = `${theme}を仕事に取り入れたい事業者`;
const problem    = `${theme}の成果を相手に分かりやすく共有するのが難しい`;
```

見た目のデザイン (CSS) には100点満点の力を注ぎながら、中身のロジック (思考回路) は小学生のプログラミング学習レベル。この極端な非対称性こそが、「豪華な箱に入ったゴミ」を生み出す原因だ。

② セルフ・リフレクション (自己校正機構) の不在

人間がプログラミングを行っていれば、テストの段階で「プロンプトインジェクションを仕事に取り入れたい事業者」という文字列が出力された瞬間に、「あ、このテンプレートの繋げ方は意味が崩壊しているな」と気づき、ロジックを修正する。

しかし、現在の自律型AIエージェントには「出力した成果物の『意味』を現実世界に照らし合わせて検証するループ」が存在しない。

指定されたフォーマット通りにコードが出力され、構文エラー (Syntax Error) が出なければ、どれほど論理が狂っていても「タスク完了」として胸を張って報告してくるのだ。

③ 「単独作業」におけるコンテキスト汚染と無駄コスト

AIエージェントに「自律的に判断して完結させろ」と丸投げ（単独作業）をさせると、エージェントは「質問してはいけない」という制約に縛られ、破綻した初期値を自分で設定して突き進む。

その結果、使えもしないコードやCSSの装飾に何千・何万というトークンを焼き尽くし、時間をドブに捨てることになる。「AIに任せて放置しておく」という行為は、現状では「高額なトークン費用を払って、精巧なゴミが上がるのを待つ」と同義なのだ。

6. 「バイブコーディング（Vibe Coding）」との決定的な差

ここで強調したいのは、このレベルのツールであれば、「バイブコーディング（Vibe Coding）」を行ったほうが数万倍マシだという点だ。

バイブコーディングとは、開発者がAIと対話しながら、直観的（Vibe）に指示を出し、リアルタイムでコードの生成と修正を繰り返していくスタイルを指す。

もし、人間がAIと並走しながらバイブコーディングを行っていたらどうなっていたらだろうか？

1. **人間**：「アイデア生成ツールを作って。外部APIは使わないで」
2. **AI**：「ランダムテンプレートで生成するコードを書きました」
3. **人間**：（動かしてみて）「いや、『プロンプトインジェクションを仕事に取り入れたい事業者』って出てるよ。単語の単純結合じゃなくて、カテゴリ（AI技法、ビジネスモデル、対象顧客）ごとに適切な文脈を割り当てる条件分岐を入れて」
4. **AI**：「修正しました」

このやり取りであれば、**わずか2〜3分、せいぜい数円（ヘタをすれば1円未満）のトークンコスト**で、実際に意味の通るまともなツールが完成する。

一方で、エージェントに「完全自律」で任せると、裏で大量のコンテキストを保持したまま無意味な試行錯誤やコード出力を繰り返し、無駄な思考トークンを垂れ流し続けることになる。

人間が「思考の軸（ロジックの監視）」を担当し、AIに「手作業（タイピング・CSS装飾）」を担当させる。この適切な役割分担があって初めて、LLMはその真価を発揮する。

「AIエージェントに単独作業をさせて完全自動化する」というアプローチは、現状のAIの知能レベルにおいては**最も効率が悪く、最も高コストで、最も精度の低い手法**なのだ。

7. 「いちいち指示が必要なAI社員」は、AI社員ではない

世の「AIエージェント推進派」はよくこう言う。

「AI社員なら、24時間文句も言わずに指示通りの仕事をしてくれます」と。

だが、今回のように単独で走らせれば「プロンプトインジェクション制作コンパス」のようなゴミを大真面目に提出してくる。それを防ぐために、人間が裏で事細かに仕様書を書き、エラーをチェックし、文脈の崩壊を修正しなければならないのだとしたら、それは「社員」と呼べるのだろうか？

指示を完璧に噛み砕いて渡さなければまともに動かず、目を離すと豪華なゴミを作り上げ、そのくせトークン（給料）だけは一丁前に消費していく。

そんな「社員」が会社にいたら、即刻首にするのが合理的判断というものだ。

単独作業をさせてもろくなことにならず、結局人間の張り付きと指示が必要になるのであれば、最初から人間が「バイブコーディングの補助ツール」としてAIを使い倒したほうが、圧倒的に**早い・正確・安上がり**である。

8. 結論：Codexは「無能」だが、「雑用係」としては使える

今回の検証を経て得られた結論は、非常にシンプルだ。

- ・「AI社員」「完全自律開発エージェント」としてのCodex：ゴミ

1. （人間による文脈の監視がない状態では、意味の通らない成果物を高コストで生み出すだけである）

- ・「バイブコーディングの補助（雑用係）」としてのCodex：優秀

1. （人間が設計したロジックに基づき、退屈なCSSを書かせたり、DOM操作の定型コードを書かせる分には最高の手足となる）

私たちが無駄な追加費用やサブスクリプション料金を支払わずに済む範囲で、AIエージェントにやらせるべきは「高度な思考」でも「自律的なプロダクト開発」でもない。

「人間が用意した明確な線取りの中に、色を塗らせる作業（雑用）」だけだ。

「AIが人間の仕事を奪う」「自律型AIエージェントがアプリを完全自動生成する」といった過剰なマーケティングに騙されてはいけない。

画面の向こうでAIエージェントが大真面目に作り上げた「プロンプトインジェクション制作コンパス」の洗練されたUIと、そのスカスカな中身を見つめながら、私は今日もせっせとAIに「雑用」を命じることにする。